



Tecnológico de Monterrey

Campus Monterrey

Tarea 2

Inteligencia artificial avanzada para la ciencia de datos

Grupo 602

Miranda Urban Solano A01752391

Domingo 20 de septiembre de 2026

Tarea 2

Ninguna familia se descubre: el contrato que uno firma

En estadística, nada es completamente objetivo. Si bien se usan herramientas matemáticas que se apegan a los datos proporcionados sin intervenir directamente en ellos, no son completamente neutros, pues la decisión de dichas herramientas depende de un tercero, cuyos conocimientos o sesgos pueden repercutir en ella. Por ejemplo, en un caso donde se deba analizar la vida útil de un lote de bombas industriales podría pensarse que lo correcto sería utilizar un modelo exponencial, ya que los datos parecen ajustarse al método y el modelo arroja un resultado utilizable. Sin embargo, existe la posibilidad de que el modelo esté representando una simplificación incorrecta del fenómeno y que sus estimaciones se encuentren bastante alejadas de la realidad.

En este contexto, elegir una distribución exponencial implica asumir que el tiempo de vida de una bomba tiene una tasa de riesgo constante. En otras palabras, se asume que la probabilidad de que una bomba falle en el siguiente instante es la misma independientemente de cuánto tiempo haya estado funcionando. Esto debido a las propiedades de este tipo de distribución: pérdida de memoria y, por ende, falta de reconocimiento del desgaste, cuyo reflejo es ignorar cuánto tiempo ha sobrevivido una bomba, pues se asume que este factor no cambia su probabilidad futura de falla. Este supuesto puede ser razonable para ciertos fenómenos, pero no para aquellos donde un componente mecánico experimenta desgaste, pues su tiempo de vida y uso pueden afectar su probabilidad de fallar. Una bomba que lleva años funcionando y acumulando desgaste no debería tener necesariamente el mismo riesgo de falla que una bomba nueva.

Aunque el problema parezca apto para el uso de una distribución exponencial dado sus características (cuenta con un solo parámetro y se modelarán tiempos), no es el modelo adecuado para resolverlo. El modelo simplifica la realidad al ignorar factores como el desgaste y la evolución del riesgo a través del tiempo. Por ello, un histograma que aparentemente se ajusta a una exponencial no es suficiente para validar el modelo ni para determinar que sus supuestos sean razonables. El modelo puede describir aproximadamente los datos observados y, aun así, representar incorrectamente el mecanismo que genera esos datos.

Además, la decisión tomada podía llevar a una predicción incorrecta, especialmente al extrapolar hacia periodos que no estaban representados adecuadamente en los datos. Si las bombas presentan desgaste, asumir una tasa de riesgo constante puede ocultar el hecho de que la probabilidad de falla aumenta con la edad, haciendo posible que muchas bombas comiencen a fallar alrededor de edades similares. Por ello el problema debe abordarse desde una perspectiva que considere la probabilidad o supervivencia de las bombas en función del tiempo y comparar el comportamiento observado con el que implicaría una tasa de riesgo constante, esto permite encontrar una solución específica para el problema que se busca resolver y no solo elegir un modelo porque en papel se ve bien.

Con lo anterior en mente, es posible afirmar que los datos no tienen mágicamente una distribución que uno simplemente descubre, sino que se elige una familia con la que pueden modelarse de acuerdo con las necesidades y supuestos del problema. Por ejemplo, en un gimnasio, los pesos utilizados en una máquina podrían producir un histograma con forma de campana y parecer compatibles con una distribución normal. Sin embargo, esa forma por sí sola no demuestra que los datos sean normales: habría que preguntarse qué representa el fenómeno, cómo se generan esos valores y si los supuestos de la distribución son razonables para ese caso. La normal podría ser un modelo útil, pero lo sería porque sus propiedades resultan adecuadas para el fenómeno que se quiere estudiar, no simplemente porque el histograma corresponda al modelo. En este caso, incluso cuando existe una justificación teórica para utilizar una determinada distribución, como ocurre con el Teorema del Límite Central, sigue siendo necesario comprobar que las condiciones que permiten esa aproximación se cumplen. Esto implica una responsabilidad: si elegir incorrectamente la familia puede producir exceso de confianza en lugar de simplemente añadir ruido aleatorio, quien modela debe ser honesto sobre los supuestos que está haciendo, comprobar que corresponden al fenómeno y reconocer las limitaciones del modelo, en lugar de presentar como un hecho objetivo una elección que depende de sus decisiones.

La mitad de la respuesta que casi nadie ve

Dado un caso de un clasificador de fraude en transacciones con un test con 99% de sensibilidad y 99% de especificidad, es importante entender las suposiciones que trae consigo, desde cómo se construyó hasta los resultados que arroja, pues estos son determinantes para entender su utilidad en un problema real.

Caso con 100,000 transacciones:

- Hay fraude en 100 ocurrencias. Hay 99 positivos verdaderos.
- El resto (99,900) no son fraude. Hay 999 falsas alarmas.
- En total hay 1,098 positivos, pero solo 99 son fraudes reales.

En resumen, cuando el modelo marca una transacción como fraude, solo alrededor del 9% de las veces realmente es fraude, a pesar de que la prueba tenga 99% de sensibilidad y 99% de especificidad. $P(+| \text{fraude}) \approx 99\%$ determina la probabilidad de que el modelo detecte fraude. Mientras que, $P(\text{fraude} | +) \approx 9.02\%$ determina la probabilidad de que esta alerta sea verdadera. Entender esta diferencia es fundamental porque el 1% de tasa base de fraude hace que incluso un pequeño porcentaje de falsas alarmas entre las 99,900 transacciones legítimas produzca muchísimos más positivos falsos que positivos verdaderos.

El error de reportar 99% de exactitud en un problema tan desbalanceado está en que un modelo que siempre dijera “no es fraude” también tiene 99.9% de accuracy, ya que el fraude ocurre solo en 1 de cada 1,000 transacciones. Se debe reportar precisión y sensibilidad, así como la matriz de confusión, ya que estos elementos permiten saber cuántos fraudes detecta el modelo y cuántas de estas alertas realmente son fraudes. Con ello, se evita que la enorme cantidad de casos negativos oculte su desempeño sobre la clase que realmente importa. En general, al trabajar con modelos, es importante entender que medidas como el accuracy no son completamente objetivas de la calidad del modelo, pues su interpretación depende de la distribución de las clases y de qué errores importan para ese caso en específico. Reportar un único número sin considerar la tasa base ni la asimetría de costos entre falsos positivos y falsos negativos no elimina las decisiones del modelador.

Correlación cero no significa que no haya relación

La correlación de Pearson puede ser cercana a cero incluso cuando existe una dependencia muy fuerte entre dos variables. Por ejemplo, se podría construir un clúster de puntos con forma de círculo, donde X representa la coordenada horizontal y Y la vertical. En este caso, conocer X restringe bastante los posibles valores de Y, por lo que claramente existe una relación entre ambas. Sin embargo, es importante considerar que esto ocurre debido a la simetría del círculo: las relaciones positivas y negativas se compensan y la correlación resulta aproximadamente cero. Esto deja claro que ρ no mide si dos variables tienen una relación en general, sino que evalúa su relación lineal. El problema aparece cuando ese único número se interpreta como una medida general de dependencia, porque detrás de ella es posible estar ignorando relaciones no lineales, grupos o estructuras que sí están presentes en los datos.

La media, la varianza y la correlación resumen los datos y, al hacerlo, necesariamente pierden parte de su estructura. Una gráfica permite ver cosas que esos números no pueden mostrar, como patrones, grupos, valores atípicos o relaciones no lineales. Aunque esto solo es posible para conjuntos de datos que lo permitan, es decir, si son pocas variables se pueden representar visualmente, pero, por ejemplo, al trabajar con un problema de cincuenta variables no es posible simplemente ponerlas todas en una gráfica y poder entenderlas por completo. Con esto en mente, es importante considerar el uso de distintas visualizaciones, seleccionar las variables más relevantes para la resolución del problema o reducir la dimensionalidad con algún método que, al igual que otras decisiones matemáticas, se adapte al problema y no solo sea el más común o el que funciona en papel. En general, sin importar qué solución se le dé, el objetivo sigue siendo explorar la estructura de los datos en lugar de asumir que un conjunto de estadísticas la representa por completo.

Esto también permite refutar la idea de que una correlación de cero significa que una variable es inútil para predecir a la otra. Si $\rho=0$, lo que sabemos es que no encontramos una relación lineal entre ellas, mas no que sean independientes ni que no exista ninguna capacidad predictiva. Nuevamente, una relación circular vuelve a demostrarlo, ya que puede existir una dependencia clara aunque la correlación sea cero. Si solo utilizamos un modelo lineal simple, una correlación

de cero implica que esa variable por sí sola no aporta una relación lineal útil para predecir la otra, pero eso no permite concluir que cualquier modelo predictivo sería inútil. La correlación permite afirmar qué tan fuerte y en qué dirección se relacionan linealmente dos variables, más no puede decirnos si dos variables dependen entre sí o si una sirve para predecir a la otra.

La independencia depende de qué estés mirando

El sesgo de selección se da cuando los individuos o grupos elegidos para un estudio no representan de forma adecuada a la población general que se quiere investigar. Supongamos que en la población general no existe una relación entre una característica biológica y la respuesta a un medicamento, pero la probabilidad de ser incluido en el ensayo depende tanto de esa característica como de otras condiciones relacionadas con la salud. Por ejemplo, históricamente muchos ensayos han excluido o limitado la participación de mujeres por considerar que las variaciones hormonales podían introducir más variabilidad en los resultados, y también pueden existir poblaciones racialmente subrepresentadas. Si analizamos únicamente a las personas que lograron entrar al ensayo, estamos condicionando en una variable de selección: estar incluido. Esa selección puede hacer que dos características parezcan relacionadas dentro de la muestra aunque esa relación no exista, o puede hacer que una relación existente en la población desaparezca. El problema no es solamente que falten datos, sino que el propio mecanismo que determinó qué datos entraron puede haber cambiado las relaciones que observamos. Además, la falta de representación tiene una consecuencia práctica: si una población está poco estudiada, los resultados obtenidos en la muestra pueden no describir adecuadamente cómo funciona el medicamento en ella.

Otro ejemplo se puede observar en la afirmación de que las personas que duermen más tienden a tener mejores resultados académicos, ya que se puede pensar en los siguientes escenarios: que dormir más causa mejores resultados, que tener mejores resultados académicos lleva a dormir más, que una tercera variable, como una menor carga de estrés, causa tanto dormir más como obtener mejores resultados, o que estamos observando únicamente a una población seleccionada de alguna manera y esa selección está creando la asociación. Los mismos datos observacionales podrían ser compatibles con las cuatro explicaciones. Para preferir una sobre las demás necesitaríamos

información adicional, como temporalidad, diseño experimental, variables relevantes que no estén observadas o evidencia de otras poblaciones.

Por esto, no necesariamente es verdad que en cuánto más variables se controlen, más cerca se está de la verdad. Controlar una variable puede ayudar a eliminar una asociación que proviene de una causa común, pero también puede introducir una asociación que no existía si esa variable es un colisionador. Incluso controlar una variable aparentemente relevante puede cambiar el signo o la magnitud de una relación y llevarnos a una conclusión distinta. Además, que una variable esté disponible en los datos no significa que sea correcto condicionarla, primero hay que preguntarse qué papel ocupa dentro de la estructura causal. Por eso, elegir qué variables entran en un modelo no es simplemente afinar un detalle técnico, implica decidir qué relaciones consideramos independientes después de condicionar y, en consecuencia, qué historia causal estamos contando, aunque no seamos conscientes de que la estamos contando.