



Tecnológico de Monterrey

Campus Monterrey

Tarea 1. Estadística en la Concentración en IA

Inteligencia artificial avanzada para la ciencia de datos

Grupo 602

Miranda Urban Solano A01752391

Domingo 30 de agosto de 2026

Ensayo sobre estadística

¿Qué hace que una creencia sea conocimiento?

Vivimos en una era en la que nos encontramos rodeados de información y datos, estos constituyen una parte importante de nuestras vidas. Con ellos se analizan comportamientos, se generan ideas y se toman decisiones, pero ¿por qué? ¿Qué hace que esa información constituya conocimiento y valor? Estamos tan acostumbrados a tratar con ellos todo el tiempo que no nos detenemos a cuestionarnos qué significan realmente, qué representan y qué razones tenemos para considerarlos como verdad. Precisamente, la epistemología, rama de la filosofía, se cuestiona el significado de lo real, de lo verdadero desde la raíz del conocimiento humano (Sotelo et al., 2023). ¿Cómo sabemos que aquello que consideramos información verdadera corresponde efectivamente con la realidad, si nuestro acceso a ella está condicionado por nuestra forma de interpretarla?

Platón, filósofo griego antiguo, distinguía la existencia de dos tipos de conocimiento: el del pensamiento común, opiniones y creencias, y el conocimiento verdadero, ideas puras y dialéctica; este último visto, como una salvación ante la ignorancia (Sotelo et al., 2023). Žižek, por su parte, influenciado fuertemente por las ideas de Lacan, plantea que lo que concebimos como realidad es una construcción social y simbólica, mientras que lo verdaderamente real aparece cuando la realidad se rompe, dando paso a aquello que resiste a ser simbolizado (Žižek, 2021). Estas definiciones, aunque diferentes entre sí, abren la puerta al cuestionamiento de lo real y lo que consideramos como parte de ello. Por ejemplo, muchas veces a la hora de describir la realidad se adoptan valores numéricos para representar lo que vemos y experimentamos, especialmente en áreas como estadística y machine learning, en donde el conocimiento se construye en gran parte a través de datos cuantitativos. Con esto en mente, resulta necesario plantearse la neutralidad, veracidad y capacidad descriptiva de los recursos que utilizamos, ya que expresar una observación mediante un número no garantiza que sea una representación neutral o completa de aquello que pretende describir.

Para entender mejor esta interrogante, se utilizará el siguiente ejemplo: podría dictarse que una creencia se convierte en conocimiento cuando se encuentra respaldada por evidencia suficiente y puede ser contrastada con la realidad. Sin embargo, Gettier (1963) no pensaba igual, él planteó una serie de casos en los que una persona puede tener una creencia verdadera y estar justificada para sostenerla, pero aun así no poseer conocimiento. Esto ocurre porque la “verdad” de la creencia puede deberse a la suerte o a una coincidencia que no es visible para el sujeto que sostiene dicha creencia. En otras palabras, una persona puede contar con una justificación aparentemente válida y llegar a una conclusión verdadera sin que exista una relación adecuada entre su justificación y la verdad de aquello que afirma porque hay ciertos elementos fuera de su percepción que influyen directa o indirectamente en ello sin que tenga el poder de saberlo.

Casos como este se presentan todo el tiempo, especialmente cuando utilizamos modelos estadísticos para predecir fenómenos. Un modelo se diseña para realizar predicciones a partir de patrones encontrados en los datos. Por lo que, al realizar predicciones “correctas” no significa que el modelo comprenda las razones detrás de los fenómenos que predice, si no que su alcance y nivel de respuesta está limitado por sus configuraciones y por la información proporcionada por terceros (Mera, 2025). En otras palabras, su perspectiva del mundo nace a partir de los datos con los que fue construido y de su diseño, por lo que la información que genera no puede considerarse una verdad absoluta, sino que debe entenderse por lo que es: predicciones basadas en datos que pueden servir como herramientas para interpretar fenómenos del mundo, pero que dependen inevitablemente de las personas involucradas en su desarrollo y aplicación.

En general, tanto en el mundo de la ciencia como en la estadística, es sumamente relevante entender que la verdad puede definirse como la mejor aproximación de nuestra realidad a comparación de cualquier otra alternativa a la que hayamos llegado hasta ahora. Además la calidad de esta aproximación depende de qué tan bien coincida con los experimentos y las observaciones, del rango en el que puede aplicarse y de qué tan robusta sea frente a intentos de refutarla mediante otras afirmaciones (Siegel, 2025). Por ejemplo, al evaluar si la creencia en la gravedad está mejor respaldada que la cosmología mexicana, se puede decir que esta última puede ser refutada con otra evidencia existente que la contradice, por lo que no puede ser calificada como la manera más

adecuada de describir ciertos fenómenos. En cambio, la teoría de la gravedad ha sido sometida a múltiples observaciones y experimentos que han destacado su capacidad de describir y predecir fenómenos dentro de determinados rangos y condiciones (Siegel, 2025). Esto no significa que la gravedad constituya una verdad absoluta e incuestionable, sino que cuenta con un grado de justificación y evidencia considerablemente mayor.

¿Qué significa un número de probabilidad?

Al hablar de inferencia estadística, se debe de diferenciar los dos enfoques de análisis: frecuentista y bayesiano. Las estadísticas frecuentistas analizan los patrones en los datos repitiendo experimentos para hacer predicciones o decisiones, tratando la probabilidad como la frecuencia de un evento que ocurre en un número infinito de pruebas. Por otro lado, las estadísticas bayesianas agregan conocimientos o creencias previas a la mezcla, actualizando estas creencias a medida que llegan nuevos datos y considerando la incertidumbre; tratan la probabilidad como medida de creencia o certeza sobre un evento de acuerdo con la disponibilidad de los datos (Mihaylova, 2025). Entender claramente esta diferencia permite elegir el mejor enfoque para el problema a estudiar, pues el tipo de interpretación que se adopte definirá cómo se verán los resultados. Por ejemplo, al analizar un caso común como la probabilidad de lluvia, la respuesta cambia completamente dependiendo si se usa un enfoque frecuentista o bayesiano. Para ilustrar mejor esta afirmación, véase el análisis de la Tabla 1.

Afirmación	“Hay un 70 % de probabilidad de lluvia mañana”	
Enfoque	Frecuentista	Bayesiano
Entendimiento de probabilidad	La probabilidad se calcula utilizando ensayos y observaciones reales para estimar las probabilidades. Por lo que para estimar las probabilidades, se repiten los experimentos una y otra vez, asignando probabilidades	La probabilidad involucra creencias individuales sobre la probabilidad. Por lo que, la probabilidad es la expectativa razonable que una persona tiene sobre la probabilidad de un evento. Las creencias

	a los eventos basados en las frecuencias relativas con las que observan resultados particulares (Thomas, 2022).	subjetivas sobre la probabilidad se pueden poner a prueba y pueden actualizarse a medida que surge nueva información y evidencia sobre eventos (Thomas, 2022).
Interpretación	Para el caso del clima, podría interpretarse como que, entre los días de agosto que presentan condiciones meteorológicas similares a las de mañana, llueve aproximadamente en el 70% de los casos.	Por ende, para el caso del clima, representa un grado de creencia basado en la información disponible (acceso a datos y conocimientos previos). La probabilidad de que llueva aproximadamente en el 70% de los casos depende del meteorólogo (observador).
Implicaciones	Este enfoque depende del conjunto de casos que se utilice como referencia (sus variables, condiciones, etc.). Por lo que, una interpretación aparentemente objetiva depende de decisiones de qué casos son comparables y qué información resulta relevante.	Este enfoque depende de la información disponible y de que esta se actualice de manera coherente cuando aparece nueva evidencia. Pero, también se ve afectada por quién decide elegir esos datos, para qué, su experiencia en el campo de estudio, así como su objetivo.

Tabla 1. Diferencias entre enfoque frecuentista y bayesiano

La elección de un enfoque por encima de otro tiene un peso importante, ya que, como se demostró en el ejemplo anterior, el tipo de análisis y los resultados obtenidos pueden diferir entre ellos. Por lo tanto, a la hora de llevar estos enfoques situaciones de la vida real, es necesario considerar las implicaciones que tiene cada herramienta, pues estas pueden ser determinantes para la toma de decisiones (Taherdoost, 2024). Por ejemplo, en el campo de la medicina, algunos clasificadores médicos analizan y pueden producir una salida porcentual para la presencia de un

tumor. Este valor aporta información, pero es necesario aprender a interpretarlo, entender de dónde proviene y qué significa en la práctica para que pueda ser verdaderamente útil. En pocas palabras, la utilidad de un número arrojado por un modelo estadístico no solamente radica en que este sea de calidad, sino también de la interpretación que se haga con él para tomar una decisión.

Además, es importante considerar la calibración del modelo. Ya que, aunque este cumpla con determinadas condiciones matemáticas para representar una distribución de probabilidad, esto no garantiza que los valores obtenidos representen probabilidades verdaderas sobre el fenómeno a estudiar (Blanco, 2026). Una red puede producir un 88% y estar mal calibrada, lo que significa que ese valor no corresponde con la frecuencia real con la que ocurren los casos para los que el modelo asigna una probabilidad similar. Por lo tanto, que un número tenga la forma de una probabilidad no significa que tenga una interpretación válida en automático ni que deba ser tratado como una certeza sobre la realidad.

En general, a lo largo de esta sección se ha mostrado que, aunque los fenómenos del mundo tengan propiedades objetivas, la probabilidad que asignamos a un evento depende del modelo utilizado y del estado de información disponible. Diferentes modelos o conjuntos de información pueden producir estimaciones distintas sobre un mismo evento, por lo que una probabilidad debe evaluarse según la calidad de la evidencia utilizada, la coherencia matemática del modelo, su capacidad predictiva y qué tan bien se calibra con observaciones posteriores (Mera, 2025). En otras palabras, aunque el número sea construido a partir de determinadas condiciones, existen criterios objetivos para evaluar qué tan razonable es esa construcción. Esto debe considerarse especialmente al hablar de IA, pues una probabilidad mal interpretada puede generar una falsa sensación de seguridad con respecto a una afirmación. Por ejemplo, en el caso de sistemas utilizados para tomar decisiones médicas, financieras o de seguridad, una predicción incorrecta puede tener consecuencias reales, incluso fatales si no se realiza un análisis correcto. Debe de comprenderse cómo está calibrado el modelo y en qué condiciones puede confiarse en él. En pocas palabras, se debe de comprender y comunicar qué tan justificada está una probabilidad y cuáles son los límites de la información que la sustenta.

Un solo número nunca es neutral

Supongamos que se requiere analizar los resultados de 11 corredores en una carrera de 5 km. Sus tiempos son de: 22, 23, 23, 24, 25, 25, 25, 26, 27, 60, 85 (minutos). En este caso, la media es de 33.18 minutos, mientras que la mediana y la moda son de 25 minutos. Reportar únicamente que el tiempo promedio fue de 33.18 minutos sería engañoso porque ningún corredor terminó cerca de ese tiempo, además hay 2 corredores que corrieron en tiempos significativamente más altos que los demás; si bien refleja un panorama con todos los valores, se ve influenciada por valores atípicos. La mediana, en cambio, representa mejor el centro de los datos, mientras que la moda muestra el tiempo que más se repitió. Elegir un solo resumen implica tomar una decisión sobre qué aspecto de los datos consideramos más representativo, además de que interviene en la percepción de nuestra muestra: define qué queremos que los demás perciban de nuestros datos (*Are Numbers Really Neutral?*, 2026).

Por otro lado, retomando el hilo de los modelos estadísticos, es importante hablar de la función de pérdida o función de error, la cual permite cuantificar el grado de error en los resultados de un modelo con base en la diferencia entre un valor predicho y un valor real con el fin de ajustar los parámetros del modelo hasta reducir la pérdida a un valor mínimo (Bergmann & Stryker, 2025). Básicamente, realizar estos ajustes permite garantizar que el modelo es capaz de generar decisiones eficientes y precisas. Con esto en mente, es posible afirmar que la elección de esta función es crítica, pues define en términos cuantitativos el éxito del modelo. Por lo que, la elección realizada tiene el poder de guiar el aprendizaje del modelo: definirá cómo será la captura de los patrones en los datos, al mismo tiempo que evita el sobreajuste o el ajuste insuficiente.

Para elegirla, se deberá tomar en cuenta factores como el tipo de análisis que se requiera realizar, los tipos de datos que se usarán, la sensibilidad que soporta el problema a analizar, la eficiencia computacional, entre otros (Alake, 2026). Podría pensarse entonces que la elección de una función de pérdida depende enteramente de estándares matemáticos o de programación, pero no, es un problema que va más allá de la elección del número que mejor se “acomode”. La

elección tiene la característica de que refleja el interés u objetivo de quien toma la decisión, pues requiere de decisiones informales, que necesariamente tienen que ser subjetivas debido a que dependen del conocimiento de la materia de quien la elige o de conflictos de interés creados por la necesidad de alcanzar cierto resultado o seguir una metodología para cumplir con ciertos requisitos, sin necesariamente ser la más efectiva (Hennig & Kutlukaya, 2022).

Lo anterior nos permite empezar a indagar en la siguiente afirmación: la estadística no es neutral. Es un área que define matemáticamente ciertos estándares, pero cuya decisión final depende de una persona y, por ende, de un factor subjetivo. Por ejemplo, piense en la unidad central de la estadística, los datos, podría pensarse que estos son naturalmente objetivos porque están basados en hechos y son solo mediciones, pero ¿es realmente así? Todos los datos que han existido fueron creados como resultado de una elección humana y eso implicó la toma de decisiones: qué se quería medir y por ende, qué se quería ignorar, qué preguntas se hicieron, cómo se categorizaron, qué ventajas u objetivos motivaron su obtención; los sesgos de estos datos permean en sus resultados (Clarke, 2025). Sumado a esto, como se ha mencionado anteriormente, los resúmenes numéricos también carecen de neutralidad porque los resultados generados a partir de los datos son la consecuencia de varias elecciones realizadas por el analista o programador que produce esos números (*Are Numbers Really Neutral?*, 2026), o sea, que el camino completo, desde la elección de datos hasta la predicción final, se ven sesgadas por juicios humanos. Es importante tener esto claro, ya que nos permite tener claridad sobre los resultados que estamos utilizando, permitiendo que no los “sigamos” ciegamente esperando una neutralidad que nunca existió y dándonos el poder de ser juiciosos respecto a su aplicación.

Para entender mejor estas implicaciones, se plantea el caso de un hospital que debe realizar una planeación cuyo enfoque puede ser calculado con base en la media o con el percentil 90. Ambas son medidas estadísticas válidas en contextos como este, pero la elección de una sobre otra tiene repercusiones que deben de considerarse además del valor matemático. Usar la media implica aceptar que existen casos que van a superar los escenarios previstos porque se asume que el promedio representa la mayor parte de los casos y que la mediana se encuentra en este rango, ignorando los casos que se alejan y que pueden ser perjudiciales porque representan

poco en cantidad, pero pueden tener un nivel de impacto más grande (Kopp, 2024). Por ejemplo, en términos de camas de hospital, se podría creer que se necesitan solo el número de camas que se aproxime al promedio de visitas/pacientes regulares, esto puede ser cierto y evitar que se tenga material que no se aproveche en periodos regulares; sin embargo, si ocurre una emergencia anómala, entonces la cantidad de camas puede no ser suficiente para ajustarse a la demanda, dejando a un porcentaje de personas sin atención y, por ende, demorando su tratamiento, algo que puede ser crítico en determinados escenarios. En cambio, si se utilizara un cálculo por percentiles, se puede reducir estos casos extremos, pues implica manejar un nivel de datos más amplio debido a que este método permite entender qué parte de la curva se está analizando y cuánta información está representada por ella, por lo que es óptima la toma de decisiones con base en ella (Kopp, 2024). Volviendo al caso de las camas de hospital, utilizar este enfoque permite tener una mejor comprensión de la importancia que evitar que un paciente llegue y no exista una cama disponible antes que la optimización de costos o espacio que podría obtenerse con la media. La decisión final requiere un juicio sobre los costos, los riesgos y las personas afectadas que no pueden calcularse con el modelo, sino que dependen de las personas encargadas.

Conclusiones

Tras el análisis de las diferentes vertientes del uso de la estadística en diferentes campos, es posible afirmar que esta no constituye una herramienta objetiva y libre de valores. Al contrario, si bien sus fundamentos se basan en procedimientos matemáticos rigurosos, su aplicación al mundo real requiere necesariamente de decisiones humanas. Por ende, la estadística debe entenderse como el uso de herramientas matemáticas para la toma de decisiones bajo objetivos, supuestos y criterios de evaluación específicos. Los modelos y sus predicciones no determinan por sí mismos el resultado más adecuado para una problemática, sino que son los analistas quienes deciden qué datos utilizar, qué variables considerar, qué medida estadística emplear y qué error es más aceptable. Estas decisiones hacen los modelos más robustos, pues evidencian que sus resultados consideran factores que incluso una computadora no podría interpretar.

Reconocer esta interpretación de la estadística es fundamental para comprender los alcances y limitaciones que se pueden lograr con los modelos. Un resultado estadístico debe interpretarse considerando no solamente el valor obtenido, sino también la distribución de los datos, los supuestos del modelo, las decisiones que lo formaron, y las consecuencias asociadas a los distintos tipos de error. Esto le da más peso al analista, pues tiene como responsabilidad producir un resultado justificado en aspectos de la realidad que quedan fuera de su representación dentro del modelo. Por ello, el análisis estadístico no debe entenderse como un proceso completamente objetivo o automático, sino como una herramienta que requiere criterio, conocimiento del contexto y una evaluación constante de sus resultados.

Referencias

- Alake, R. (2026, 6 mayo). *Loss Functions in Machine Learning Explained*. <https://www.datacamp.com/tutorial/loss-function-in-machine-learning>
- Are numbers really neutral?* (2026, 21 enero). Population Reference Bureau. <https://www.prb.org/news/are-numbers-really-neutral/>
- Bergmann, D., & Stryker, C. (2025, 26 noviembre). Función de pérdida. *Think*. <https://www.ibm.com/mx-es/think/topics/loss-function>
- Blanco, P. (2026, 5 agosto). *¿Qué es la explicabilidad en IA y por qué es importante?* Blog de Tecnología - Euroinnova. <https://tecnologia.euroinnova.com/explicabilidad>
- Clarke, S. (2025, 29 julio). The Illusion of Neutrality: Why Data is Always Political. *From Here to Ontology*. <https://steffclarke.substack.com/p/the-illusion-of-neutrality-why-data>
- Gettier, E. L. (1963). Is justified true belief knowledge? *Analysis*, 23(6), 121-123. <https://doi.org/10.1093/analys/23.6.121>
- Hennig, C., & Kutlukaya, M. (2022). Some Thoughts About the Design of Loss Functions. *REVSTAT – Statistical Journal*. <https://doi.org/10.57805/revstat.v5i1.40>
- Kopp, M. (2024, 23 septiembre). Why averages suck and percentiles are great. *Dynatrace News*. <https://www.dynatrace.com/news/blog/why-averages-suck-and-percentiles-are-great/>
- Mera, J. (2025, 19 noviembre). *Modelos de predicción: todos los detalles de este proceso matemático*. Canal Informática y TICS. <https://www.inesem.es/revistadigital/informatica-y-tics/modelos-de-prediccion>
- Mihaylova, M. (2025, 9 noviembre). *Frequentist vs. Bayesian: The Basics — MMLabs*. MMLabs. <https://www.mmlabs.ch/blog/bayesian-vs-frequentist-in-meta-analyses>
- Siegel, E. (2025, 11 diciembre). *Does science reveal the absolute truth about reality?* Big Think. <https://bigthink.com/starts-with-a-bang/science-absolute-truth/>
- Sotelo, D. O., Fernández, I. B., & Aranda, L. A. V. (2023). Qué es eso llamado epistemología, para qué sirve, por qué es inexcusable para la universidad y para la paz. *Reencuentro Análisis de Problemas Universitarios*, 35(86), 295-320. <https://doi.org/10.24275/uamxoc-dcsh/reencuentro/202386-14>
- Taherdoost, H. (2024, 16 enero). *Decision Making: Models, Processes, Techniques*. Taherdoost. <https://encyclopedia.pub/entry/53905>

Thomas, S. (2022, 17 octubre). Understanding Math Probability - Definition, Formula & How To Find It. *Outlier*. <https://articles.outlier.org/understanding-math-probability#section-how-is-probability-measured>

Zizek, S. (2021). *¡Goza tu síntoma!*